LAPORAN

PRAKTIKUM DATA SIENCE PRAKTISI

Laporan Hasil Model dan Evaluasi NER

Oleh:

Alvina Nur Laila Anggraini / 244311003
Dheandra Khairunnisa Pambudi / 244311009
Nadia Tifara Sidiq / 2443110022

JURUSAN TEKNIK
PROGRAM STUDI TRPL
POLITEKNIK NEGERI MADIUN
2026

1. Pendahuluan

Proyek ini mengembangkan model Named Entity Recognition (NER) untuk mengenali entitas pada artikel berita. Label yang digunakan adalah DATE, EVENT, GPE, ORG, dan PERSON. Model pretrained spaCy en_core_web_sm digunakan sebagai baseline, kemudian diadaptasi menggunakan data anotasi proyek.

2. Dataset dan Pembagian Data

Dataset berasal dari file anotasi artikel berita. Notebook mencatat 120 baris pada CSV awal; setelah penyaringan bahasa, konversi anotasi, dan pemeriksaan rentang entitas, terdapat 100 artikel yang siap diproses. Pembagian data yang digunakan adalah:

Split	Jumlah artikel	Proporsi dari 100 artikel
Training	69	69%
Validasi	17	17%
Pengujian akhir	14	14%

Notebook memeriksa agar ID artikel tidak tumpang tindih antar-split. Satu baris anotasi kosong ditemukan pada pemeriksaan awal; proses konversi berikutnya mencatat 100 artikel siap diproses tanpa masalah rentang yang belum terselesaikan.

3. Metode Evaluasi

Evaluasi menggunakan exact-span matching. Prediksi dihitung benar jika start offset, end offset, dan label entitas sama persis dengan anotasi acuan. Precision dihitung sebagai TP/(TP+FP), recall sebagai TP/(TP+FN), dan F1-score sebagai rata-rata harmonik precision dan recall. Evaluasi dilaporkan terpisah untuk data validasi dan data pengujian akhir, baik secara keseluruhan maupun per label.

4. Hasil Evaluasi Keseluruhan

Angka berikut diambil dari output notebook Training_Model_NER_UTS (1).ipynb di repository ZIP. Nilai validasi berasal dari baseline dan checkpoint terbaik (epoch 18); nilai pengujian berasal dari evaluasi exact-span + label pada 14 artikel yang telah direview.

Split	Model	Precision	Recall	F1-score
Validasi	Baseline	0,1785	0,6029	0,2754
Validasi	Model hasil training	0,9676	0,9890	0,9782
Pengujian akhir	Baseline	0,1795	0,5780	0,2740

Pengujian akhir	Model hasil training	0,9506	0,9854	0,9677

Berdasarkan angka tersebut, model hasil training menunjukkan peningkatan dibanding baseline. Pada pengujian akhir, ringkasan sebelumnya mencatat 404 true positive, 21 false positive, dan 6 false negative untuk model hasil training. Nilai-nilai ini perlu diverifikasi kembali karena notebook saat ini meminta test set yang sudah direview sebelum evaluasi final dijalankan.

5. Matrik Per Label

Tabel berikut menyalin metrik per label yang tercetak pada output repository. PENTING: agregasi per label pada output repository tidak konsisten dengan evaluasi keseluruhan (misalnya TP per label berjumlah jauh lebih besar daripada 410 entitas gold pada test set). Karena itu, angka per label dicantumkan sesuai sumber tetapi belum boleh dianggap valid; hitung ulang dari satu perbandingan exact-span yang sama.

Label	Precision	Recall	F1-score	Catatan
DATE	1,000000	1,000000	1,000000	TP=6.133; FP=0; FN=0
ORG	0,891029	0,992034	0,938823	TP=1.619; FP=198; FN=13
GPE	0,903827	0,970061	0,935774	TP=5.573; FP=593; FN=172
PERSON	1,000000	0,973684	0,986667	TP=37; FP=0; FN=1
EVENT	Tidak tersedia	Tidak tersedia	Tidak tersedia	Tidak muncul pada output model terlatih

6. Konfigurasi Pelatihan

Parameter	Nilai dari notebook
Framework/model dasar	spaCy / en_core_web_sm
Random seed	42
Epoch maksimum	20
Batch size	8
Dropout	0,20
Pemilihan checkpoint	F1-score validasi terbaik
Epoch terbaik	Epoch ke-18
Durasi pelatihan	16
Distribusi kelas	DATE, EVENT, GPE, ORG, dan PERSON

7. Analisis Pelatihan pada Test Set

Tiga contoh di bawah diambil dari daftar false positive/false negative pada output test repository. Kategori kesalahan ditentukan dengan membandingkan tuple (start, end, label) prediksi dengan anotasi acuan.

No.	Jenis kesalahan	Teks entitas	Label	Analisis konteks
1	False positive	Saudi Arabia	GPE	Diprediksi sebagai lokasi oleh model, tetapi tidak tercatat sebagai rentang+label yang sama pada anotasi acuan.
2	False negative	Asean	GPE	Entitas ada pada anotasi acuan, tetapi model tidak menghasilkan prediksi dengan rentang dan label yang sama.
3	False negative	Datuk Khairussaleh Ramli	PERSON	Nama orang pada anotasi acuan tidak dikenali dengan rentang dan label yang sama oleh model.

8. Pengaruh Data Pengujian terhadap Anotasi dan Tuning

Sesuai rancangan notebook, checkpoint model dipilih berdasarkan F1-score validasi, sedangkan test set disiapkan untuk review dan evaluasi akhir. Untuk menjaga evaluasi tetap objektif, data pengujian tidak boleh digunakan untuk memilih hyperparameter, memilih checkpoint, atau tuning model. Jika tim melakukan perubahan anotasi berdasarkan hasil review test, perubahan tersebut harus dicatat secara transparan; setelah test dipakai untuk pengembangan, hasilnya tidak lagi dapat dianggap sebagai evaluasi final yang sepenuhnya independen.

Berdasarkan alur notebook, checkpoint dipilih berdasarkan F1-score validasi, bukan test. Namun, CSV test harus direview dan diberi status REVIEWED sebelum evaluasi akhir. Laporan harus menyatakan secara jujur apakah review test mengubah anotasi atau tuning. Jika tidak ada perubahan model/anotasi berdasarkan test, pernyataan yang sesuai adalah: “Data pengujian digunakan untuk pemeriksaan anotasi dan evaluasi akhir, bukan untuk pemilihan checkpoint atau tuning model.”

9. Demonstrasi Layanan

Demonstrasi layanan harus memuat model hasil training yang sama dengan model yang dievaluasi, yaitu artefak ner_custom_v1. Alur demonstrasi adalah: (1) memuat model ner_custom_v1; (2) memasukkan judul dan isi artikel; (3) mengirim teks ke endpoint POST /extract-entities; (4) menampilkan teks entitas, label, start offset, dan end offset; serta (5) menguji beberapa contoh teks dan membandingkan hasilnya dengan anotasi acuan. Jangan menggunakan baseline atau model lain untuk menggantikan model yang dilaporkan.

10. Kesimpulan

Notebook mengimplementasikan pipeline NER berbasis spaCy dengan lima label entitas dan pembagian data train, validasi, serta test yang terpisah. Ringkasan evaluasi sebelumnya menunjukkan peningkatan model hasil training dibanding baseline. Akan tetapi, laporan belum dapat dianggap final secara numerik sebelum output evaluasi terbaru diverifikasi, tabel per label dilengkapi, dan minimal tiga kesalahan aktual dari test set dimasukkan. Demonstrasi layanan juga harus memakai artefak ner_custom_v1 yang sama dengan checkpoint yang dievaluasi.